

Laboratorio 3 — Neo4j

Grafo de Explicabilidad para Auditoría de Clasificación Normativa

Autores: Matías Barraza H. · [Nombre integrante 2] · [Nombre integrante 3]

e-mails: matias.barrazah@usm.cl · [correo2] · [correo3]

Profesor: Mauricio Figueroa Colarte

Universidad Técnica Federico Santa María — Departamento de Informática

Resumen

El presente informe documenta la construcción, en Neo4j, de un grafo de explicabilidad orientado a auditar las decisiones de un agente de inteligencia artificial que clasificó 129 normativas del Servicio de Impuestos Internos (SII) como Relevantes o No Relevantes para el cumplimiento normativo de una empresa Fintech. A partir del archivo `normativas_clasificadas_IA.csv` se modeló un grafo de propiedades que representa la normativa como nodo central y conecta su clasificación IA, su explicación, el agente que la generó, la fuente, el tipo documental, las reglas de negocio activadas, la evidencia textual de respaldo y la auditoría humana.

La metodología consistió en: (i) cargar e importar el dataset con LOAD CSV; (ii) etiquetar los nodos según tipo documental (:Circular, :Resolucion), clasificación (:Relevante, :NoRelevante) y explicabilidad (:ExplicacionValida, :ExplicacionDebil, :RequiereRevision, :Auditada); (iii) aplicar 18 reglas de negocio preestablecidas (12 palabras clave y 6 referencias normativas); (iv) generar evidencia textual por cada regla activada; y (v) ejecutar las cinco consultas de explicabilidad obligatorias más una auditoría humana simulada de seis normativas.

Entre los resultados principales se observó que 90 de las 129 normativas activan al menos una regla de negocio y que 70 normativas clasificadas como No Relevante por la IA activan reglas de negocio, lo que constituye una inconsistencia entre la clasificación automática y los criterios del negocio. El grafo permite recorrer la ruta explicable Normativa → Clasificación IA → Explicación IA → Regla de negocio → Evidencia textual → Auditoría humana y responder, para cada normativa, la pregunta central: ¿la clasificación asignada por la IA está suficientemente explicada y es válida para el negocio? El principal aprendizaje es que el modelo de grafo transforma un resultado tabular opaco en una estructura trazable y auditable.

1. Introducción

Las empresas del sector financiero (Fintech) están sujetas a un marco de cumplimiento normativo tributario en permanente cambio. El SII publica circulares y resoluciones que pueden afectar directamente la operación del negocio, por lo que monitorear cuáles son relevantes es una tarea crítica. Para apoyar este proceso, un agente de IA —basado en procesamiento de lenguaje natural (NLP) y en una arquitectura de Recuperación Aumentada por Generación (RAG)— clasificó cada normativa como Relevante o No Relevante y entregó una explicación textual de su decisión.

Sin embargo, una decisión automatizada no debe aceptarse sin revisión. El equipo humano de cumplimiento necesita comprender por qué la IA asignó una clasificación, qué evidencia respalda esa decisión y si la explicación entregada es válida para el negocio. El resultado de la IA se encuentra en formato tabular (CSV), lo que permite saber el veredicto pero dificulta auditar el razonamiento, porque las relaciones entre normativa, explicación, reglas y evidencia quedan implícitas.

Este trabajo aborda dicho problema mediante un grafo de explicabilidad en Neo4j. Las bases de datos de grafos representan de forma natural entidades altamente conectadas y permiten recorrer relaciones de manera explícita y eficiente, lo que las hace idóneas para tareas de explicabilidad y auditoría (XAI). El objetivo general es construir un grafo que permita representar, consultar y auditar las decisiones del agente IA. Los objetivos específicos incluyen modelar normativas, clasificaciones, explicaciones, fuentes, tipos documentales, reglas de negocio y evidencias; consultar el grafo para explicar las clasificaciones; determinar la validez de las explicaciones; e identificar normativas que requieren revisión humana por baja explicabilidad, falta de evidencia o contradicción entre la clasificación y las reglas de negocio.

2. Desarrollo

Nota sobre las evidencias gráficas. Por cada requisito se describe el paso a paso y el código Cypher utilizado (incluido íntegramente en el archivo *lab3_neo4j.cypher*). Los recuadros punteados indican el lugar donde debe insertarse la captura correspondiente de Neo4j Browser tras ejecutar el script.

2.1 Construcción del grafo desde el dataset

El grafo se construye a partir del archivo *normativas_clasificadas_IA.csv* (129 filas, 8 columnas). Previo a la carga se definen restricciones de unicidad para garantizar idempotencia (que el script pueda re-ejecutarse sin duplicar nodos) y mejorar el rendimiento de los MERGE:

```
CREATE CONSTRAINT normativa_name IF NOT EXISTS
  FOR (n:Normativa) REQUIRE n.name IS UNIQUE;
// (análogas para Fuente, TipoDocumento, AgenteIA, ReglaNegocio,
// ClasificacionIA, ExplicacionIA, EvidenciaTextual, AuditoriaHumana)
```

La importación con LOAD CSV crea, por cada fila, el nodo central :Normativa y lo conecta con su Fuente, su Tipo de documento, su Clasificación IA y su Explicación IA, además del Agente IA (nodo único):

```
LOAD CSV WITH HEADERS FROM 'file:///normativas_clasificadas_IA.csv' AS row
WITH row WHERE row.name IS NOT NULL AND trim(row.name) <> ''
MERGE (n:Normativa {name: trim(row.name)})
  SET n.description=row.description, n.url=row.url,
  n.cuerpo=row.cuerpo, n.relevancia=row.relevancia,
  n.explicacion=row.explicacion, n.tipo_documento=row.tipo_documento
MERGE (f:Fuente {nombre: trim(row.fuente)})
MERGE (n)-[:EMITIDA_POR]->(f)
MERGE (td:TipoDocumento {nombre: trim(row.tipo_documento)})
MERGE (n)-[:ES_TIPO]->(td)
MERGE (c:ClasificacionIA {id: trim(row.name)}) SET c.valor=row.relevancia
MERGE (n)-[:TIENE_CLASIFICACION]->(c) ;
```

Limpieza y normalización. Durante la carga se normalizan los datos: se aplica trim() a los identificadores (nombre, fuente, tipo documental) para evitar nodos duplicados por espacios; se filtran filas sin nombre; se conserva el archivo en UTF-8 (la marca BOM del CSV es manejada por Neo4j 5.x); y se calcula la propiedad derivada len_explicacion para soportar las reglas de explicabilidad. Se preservan íntegros los campos relevantes del dataset (description, url, cuerpo, relevancia, explicacion, fuente).

El modelo de datos resultante (esquema del grafo) se resume en las siguientes tablas de nodos y relaciones.

Tabla 1: Tipos de nodo del grafo de explicabilidad

Etiqueta de nodo	Descripción	Cardinalidad
:Normativa	Nodo central; una por fila del CSV	129
:ClasificacionIA	Veredicto de la IA (Relevante/No Relevante)	129
:ExplicacionIA	Texto de la explicación generada	129
:AgenteIA	Agente NLP+RAG que clasifica (nodo único)	1
:Fuente	Subdirección del SII que emite	11
:TipoDocumento	Circular / Resolución	2
:ReglaNegocio	Regla de relevancia (palabra clave o referencia)	18
:EvidenciaTextual	Fragmento que respalda una regla activada	≈ por activación
:AuditoriaHumana	Juicio humano sobre la normativa	6

Tabla 2: Relaciones del grafo

Relación	Significado
(:Normativa)-[:TIENE_CLASIFICACION]->(:ClasificacionIA)	La normativa recibe un veredicto
(:ClasificacionIA)-[:GENERADA_POR]->(:AgenteIA)	El agente IA produjo la clasificación
(:Normativa)-[:CLASIFICADA_POR]->(:AgenteIA)	Trazabilidad directa al agente (Figura 1)
(:ClasificacionIA)-[:TIENE_EXPLICACION]->(:ExplicacionIA)	La clasificación posee una explicación
(:Normativa)-[:TIENE_EXPLICACION]->(:ExplicacionIA)	Acceso directo a la explicación
(:Normativa)-[:EMITIDA_POR]->(:Fuente)	Subdirección emisora
(:Normativa)-[:ES_TIPO]->(:TipoDocumento)	Circular o Resolución
(:Normativa)-[:ACTIVA_REGLA]->(:ReglaNegocio)	Regla de negocio detectada
(:Normativa)-[:RESPALDADA_POR]->(:EvidenciaTextual)	Evidencia textual de respaldo
(:EvidenciaTextual)-[:EVIDENCIA_DE]->(:ReglaNegocio)	La evidencia justifica una regla
(:Normativa)-[:AUDITADA_POR]->(:AuditoriaHumana)	Revisión del equipo humano

Este diseño satisface la ruta conceptual esperada Normativa → Clasificación IA → Explicación IA → Regla de negocio → Evidencia textual → Auditoría humana, manteniendo a la Normativa como nodo central (hub) tal como muestra la Figura 1 del enunciado.

[ESPACIO PARA CAPTURA DE NEO4J BROWSER]

Figura 2: Vista general del grafo en Neo4j Browser (MATCH p=(n:Normativa)-[r]-(x) RETURN p LIMIT 200)

2.2 Representación de clasificación, explicación y evidencia

Cada normativa expone su clasificación y su explicación como nodos propios, lo que permite consultarlas de forma independiente y recorrer la cadena de razonamiento. La evidencia textual se materializa como nodos :EvidenciaTextual que guardan el fragmento de la normativa (descripción/cuerpo) asociado a cada regla activada, junto con el campo donde se detectó la coincidencia. La distribución del dataset cargado es la siguiente:

Tabla 3: Distribución de las 129 normativas cargadas

Dimensión	Categoría	Cantidad
Clasificación IA	Relevante	20
Clasificación IA	No Relevante	109
Tipo documental	Resolución	83
Tipo documental	Circular	46
Explicación	Débil (< 200 caracteres)	5
Explicación	Suficiente (≥ 200 caracteres)	124

La cadena explicable de una normativa concreta queda representada por nodos y relaciones que pueden visualizarse directamente en el navegador, mostrando clasificación, explicación, reglas y evidencia conectadas al nodo normativa.

[ESPACIO PARA CAPTURA DE NEO4J BROWSER]

Figura 3: Ruta explicable de una normativa (clasificación, explicación, reglas y evidencia)

2.3 Aplicación de reglas de negocio y etiquetas

Se modelaron 18 reglas de negocio preestablecidas como nodos :ReglaNegocio: 12 por palabra clave (Tabla 3 del enunciado) y 6 por referencia normativa relevante (Tabla 2 del enunciado). Una normativa activa una regla si el patrón aparece, sin distinguir mayúsculas, en la concatenación de nombre + descripción + cuerpo + explicación.

Decisión de modelamiento (control de falsos positivos). Para los tokens cortos «POS» y «P.O.S» no se usó CONTAINS sino una coincidencia con límite de palabra (expresión regular «\b»), porque «pos» como subcadena aparece dentro de palabras como «disposiciones» o «depósito». Sin este ajuste, la regla POS se activaba 107 veces (con falsos positivos); con el ajuste se activa 62 veces de forma correcta.

```
UNWIND $reglas AS regla
MERGE (rn:ReglaNegocio {nombre: regla.nombre})
  SET rn.categoria=regla.categoria, rn.modo=regla.modo, rn.patron=regla.patron;

MATCH (n:Normativa), (rn:ReglaNegocio)
WITH n, rn, toLower(n.name+' '+n.description+' '+n.cuerpo+' '+n.explicacion) AS blob
WHERE (rn.modo='contains' AND blob CONTAINS toLower(rn.patron))
  OR (rn.modo='regex' AND blob =~ rn.patron)
MERGE (n)-[:ACTIVA_REGLA]->(rn)
MERGE (ev:EvidenciaTextual {id: n.name+' '::'+rn.nombre})
  SET ev.regla=rn.nombre, ev.fragmento=substring(n.description,0,280)
MERGE (n)-[:RESPALDADA_POR]->(ev)
MERGE (ev)-[:EVIDENCIA_DE]->(rn);
```

Tabla 4: Reglas de negocio y número de normativas que las activan

Regla (patrón)	Tipo	N° normativas que la activan
cumplimiento tributario	Palabra clave	82
boleta	Palabra clave	76
medios de pago electrónicos	Palabra clave	74
inicio de actividades	Palabra clave	68
comercio electrónico	Palabra clave	65
POS	Palabra clave	62
operadores y administradores	Palabra clave	60
registro de compra	Palabra clave	22
registro de venta	Palabra clave	16
Artículo 68 del Código Tributario	Referencia	6
Resolución 176 de 2020	Referencia	2
Resolución 76 de 2021	Referencia	2
Circular 38 de 2025	Referencia	1
comprobante electrónico / puntos de venta / P.O.S	Palabra clave	0
Resolución 79 de 2025 / Resolución 59 de 2025	Referencia	0

Respecto de las etiquetas obligatorias, además de :Normativa, :Circular, :Resolucion, :Relevante y :NoRelevante (asignadas según las propiedades), se definieron las etiquetas de explicabilidad mediante las siguientes reglas: una normativa es :ExplicacionDebil si su explicación tiene menos de 200 caracteres (típicamente el texto genérico «No cumple reglas de negocio.»), y :ExplicacionValida en caso contrario. Se marca :RequiereRevision cuando la explicación es débil, o cuando existe inconsistencia entre la clasificación y las reglas (No Relevante que activa reglas, o Relevante que no activa ninguna). Finalmente, se marca :Auditada a las normativas revisadas por el equipo humano.

```

MATCH (n:Normativa) WHERE n.tipo_documento='Circular'      SET n:Circular;
MATCH (n:Normativa) WHERE n.relevancia='Relevante'         SET n:Relevante;
MATCH (n:Normativa) WHERE n.len_explicacion < 200          SET n:ExplicacionDebil;
MATCH (n:ExplicacionDebil)                                 SET n:RequiereRevision;
MATCH (n:NoRelevante) WHERE (n)-[:ACTIVA_REGLA]->()        SET n:RequiereRevision;
MATCH (n:Relevante) WHERE NOT (n)-[:ACTIVA_REGLA]->()      SET n:RequiereRevision;

```

[ESPACIO PARA CAPTURA DE NEO4J BROWSER]

Figura 4: Normativas etiquetadas como Relevante / No Relevante con sus reglas de negocio

2.4 Consultas de explicabilidad

Se desarrollaron las cinco consultas obligatorias. A continuación se describe el objetivo, la consulta Cypher y el resultado esperado de cada una; las capturas de resultados deben adjuntarse en los recuadros indicados.

Consulta 1 — Clasificación general. Lista las normativas Relevantes y No Relevantes con nombre, tipo documental, fuente, descripción y explicación IA.

```

MATCH (n:Normativa)-[:EMITIDA_POR]->(f:Fuente)
MATCH (n)-[:ES_TIPO]->(td:TipoDocumento)
MATCH (n)-[:TIENE_CLASIFICACION]->(c)-[:TIENE_EXPLICACION]->(e)
RETURN c.valor AS clasificacion_IA, td.nombre AS tipo, n.name AS normativa,
       f.nombre AS fuente, n.description AS descripcion, e.texto AS explicacion_IA
ORDER BY clasificacion_IA DESC, tipo, normativa;

```

Resultado esperado: 129 filas (20 Relevantes y 109 No Relevantes).

[ESPACIO PARA CAPTURA DE NEO4J BROWSER]

Figura 5: Resultado de la Consulta 1 (tabla de clasificación general)

Consulta 2 — Explicación de una normativa específica. Muestra clasificación IA, explicación, reglas activadas y evidencia textual de una normativa (ej.: «Circular N° 12 del 30 de Enero del 2025»).

```
MATCH (n:Normativa {name:'Circular N° 12 del 30 de Enero del 2025'})
MATCH (n)-[:TIENE_CLASIFICACION]->(c)-[:TIENE_EXPLICACION]->(e)
OPTIONAL MATCH (n)-[:ACTIVA_REGLA]->(rn)
OPTIONAL MATCH (n)-[:RESPALDADA_POR]->(ev)-[:EVIDENCIA_DE]->(rn)
RETURN n.name, c.valor, e.texto,
       collect(DISTINCT rn.nombre) AS reglas,
       collect(DISTINCT ev.fragmento) AS evidencia;
```

[ESPACIO PARA CAPTURA DE NEO4J BROWSER]

Figura 6: Resultado de la Consulta 2 (explicación de una normativa)

Consulta 3 — Relevantes con respaldo de negocio. Identifica normativas Relevantes que activan reglas de negocio y cuentan con evidencia textual.

```
MATCH (n:Relevante)-[:ACTIVA_REGLA]->(rn)
MATCH (n)-[:RESPALDADA_POR]->(ev)-[:EVIDENCIA_DE]->(rn)
RETURN n.name, count(DISTINCT rn) AS n_reglas,
       collect(DISTINCT rn.nombre) AS reglas, count(DISTINCT ev) AS n_evidencias
ORDER BY n_reglas DESC;
```

Resultado esperado: las 20 normativas Relevantes activan reglas y poseen evidencia (ninguna Relevante queda sin respaldo).

[ESPACIO PARA CAPTURA DE NEO4J BROWSER]

Figura 7: Resultado de la Consulta 3 (Relevantes con respaldo de negocio)

Consulta 4 — Posibles inconsistencias. Detecta No Relevantes que activan reglas de negocio, o Relevantes que no activan ninguna regla.

```
MATCH (n:NoRelevante)-[:ACTIVA_REGLA]->(rn)
RETURN 'No Relevante activa reglas' AS tipo, n.name,
       count(DISTINCT rn) AS n_reglas ORDER BY n_reglas DESC
UNION
MATCH (n:Relevante) WHERE NOT (n)-[:ACTIVA_REGLA]->()
RETURN 'Relevante sin reglas' AS tipo, n.name, 0 AS n_reglas;
```

Resultado esperado: 70 normativas No Relevantes activan reglas de negocio (inconsistencia) y 0 Relevantes carecen de reglas. Este es el principal hallazgo de auditoría del trabajo.

[ESPACIO PARA CAPTURA DE NEO4J BROWSER]

Figura 8: Resultado de la Consulta 4 (inconsistencias clasificación–reglas)

Consulta 5 — Revisión humana. Identifica normativas con explicación débil, insuficiente o poco alineada con las reglas (etiqueta :RequiereRevision), indicando el motivo.

```
MATCH (n:RequiereRevision)
MATCH (n)-[:TIENE_CLASIFICACION]->(c)-[:TIENE_EXPLICACION]->(e)
OPTIONAL MATCH (n)-[:ACTIVA_REGLA]->(rn)
RETURN n.name, c.valor, e.longitud AS largo_explicacion,
       count(DISTINCT rn) AS n_reglas,
       CASE WHEN c.valor='No Relevante' AND count(DISTINCT rn)>0
```

```

THEN 'No Relevante activa reglas'
WHEN n.len_explicacion<200 THEN 'Explicación insuficiente'
ELSE 'Otra' END AS motivo
ORDER BY n_reglas DESC, largo_explicacion ASC;

```

[ESPACIO PARA CAPTURA DE NEO4J BROWSER]

Figura 9: Resultado de la Consulta 5 (normativas que requieren revisión humana)

2.5 Auditoría humana simulada

Se auditaron seis normativas (más del mínimo de cinco exigido). Por cada una se creó un nodo :AuditoriaHumana con el juicio del grupo —Validada, Corregida o Requiere más antecedentes— y su justificación, conectado mediante (:Normativa)-[:AUDITADA_POR]->(:AuditoriaHumana). La tabla resume los casos seleccionados, escogidos para cubrir los tres tipos de juicio.

Tabla 5: Auditoría humana simulada

Normativa revisada	Clasif. IA	Juicio	Justificación (resumen)
Circular N° 12 del 30 de Enero del 2025	Relevante	Validada	Activa reglas (boleta, cumplimiento tributario) con evidencia coherente; explicación suficiente y trazable.
Res. Exenta SII N° 79 del 26 de Junio del 2025	Relevante	Validada	Activa 4 reglas con evidencia sólida y explicación bien desarrollada; decisión trazable.
Res. Exenta SII N° 81 del 30 de Junio del 2025	No Relevante	Corregida	Activa 9 reglas de negocio con evidencia; a juicio humano debería ser Relevante (inconsistencia).
Res. Exenta SII N° 59 del 06 de Mayo del 2025	No Relevante	Corregida	Activa múltiples reglas (boletas, medios de pago); la evidencia contradice la clasificación.
Circular N° 13 del 07 de Febrero del 2025	No Relevante	Requiere más antecedentes	Explicación genérica de 28 caracteres; evidencia insuficiente para auditar.
Res. Exenta SII N° 05 del 09 de Enero del 2025	No Relevante	Requiere más antecedentes	Explicación < 200 caracteres; baja explicabilidad, requiere revisión adicional.

[ESPACIO PARA CAPTURA DE NEO4J BROWSER]

Figura 10: Subgrafo de auditoría humana (normativas :Auditada y sus juicios)

3. Conclusiones

- El modelo de grafo cumple su propósito de explicabilidad: convierte un resultado tabular opaco en una estructura navegable donde la ruta Normativa → Clasificación → Explicación → Regla → Evidencia → Auditoría puede recorrerse explícitamente, respondiendo a la pregunta central sobre si cada clasificación está suficientemente explicada y es válida para el negocio.
- Neo4j aporta valor frente a un modelo tabular porque las relaciones son ciudadanos de primera clase: consultas como «No Relevantes que activan reglas» o «Relevantes sin respaldo» se expresan de forma directa con patrones de grafo, sin uniones costosas, y se visualizan de inmediato.

- Sobre la validez de las explicaciones, se detectó un hallazgo relevante: 70 de las 109 normativas clasificadas como No Relevante activan al menos una regla de negocio. Esto evidencia una posible sub-clasificación de la IA o, alternativamente, que las palabras clave del negocio son demasiado amplias (términos como «cumplimiento tributario» o «boleta» aparecen en la mayoría de los documentos del SII). En ambos casos, el grafo cumple su función de levantar la inconsistencia para revisión humana.
- Los casos que requieren revisión humana se identifican de forma sistemática mediante etiquetas: 5 normativas presentan explicación débil (< 200 caracteres, texto genérico) y un amplio conjunto presenta inconsistencia clasificación–reglas. La auditoría simulada validó 2 normativas, corrigió 2 por inconsistencia y solicitó más antecedentes en 2 por baja explicabilidad.
- Limitaciones del enfoque: la detección de reglas se basa en coincidencia léxica (substring / regex), por lo que no captura sinonimia ni contexto semántico y puede generar falsos positivos —mitigados parcialmente con límites de palabra para tokens cortos como «POS»—. Una extensión natural sería incorporar embeddings o búsqueda semántica para complementar las reglas léxicas, y enriquecer la evidencia textual con el fragmento exacto que rodea cada coincidencia.

4. Referencias Bibliográficas

1. Arrieta, A. B., et al. (2020). Explainable artificial intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI. *Information Fusion*, 58, 82–115.
2. Neo4j. (s. f.). *The Neo4j Cypher Manual*. <https://neo4j.com/docs/cypher-manual/current/>
3. Neo4j. (s. f.). *What is graph data modeling?* <https://neo4j.com/docs/getting-started/data-modeling/>
4. Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). “Why should I trust you?": Explaining the predictions of any classifier. *Proceedings of the 22nd ACM SIGKDD*, 1135–1144.
5. Robinson, I., Webber, J., & Eifrem, E. (2015). *Graph databases: New opportunities for connected data* (2.^a ed.). O'Reilly Media.